

垃圾分类研究汇报讲稿（完整生动版）

各位老师好，我是2023级广播电视工程的赵家晖。今天啊，我要带大家走进一场特别的“破案”过程——我们的案件，就是**如何让机器学会垃圾分类**。

【第一幕：糟糕的起点】

好，我们先看第一阶段——最基础的实验。

我们直接把垃圾图片的原始像素，喂给几个经典算法。结果呢？

KNN 40%，逻辑回归33%，最好的SVM也只有57%。

你看，连及格线都不到。

为什么这么差？

我举个例子啊：你把一张揉皱的餐巾纸和一张压扁的易拉罐照片，直接转换成数字像素——在机器眼里，这就是两团杂乱无章的数字点。它根本看不出“**纸**”的柔软纹理和“**金属**”的反光特性有什么区别。

这就像让你只看一幅画的像素点，而不是看画的整体，你当然分不清画的是山还是水。

所以结论就是：**原始像素不行，我们必须给机器“戴上一副眼镜”。**

【第二幕：三副不同的“眼镜”】

第二阶段，我们给机器准备了**三副眼镜**，也就是三种特征：

第一副：HOG眼镜（看形状轮廓）

它擅长捕捉边缘。比如对一个**完好的玻璃瓶**，它能清晰地提取出瓶身的直线和瓶口的圆形。

实验里，SVM的准确率从57%提到了63%。

但是！问题来了。如果是一个**被捏扁的易拉罐**，或者一个**揉成一团的纸球**，它们的形状每次都不一样，HOG提取的轮廓就会千奇百怪，机器就被搞糊涂了。所以，只靠形状，不稳定。

第二副：LBP眼镜（看表面纹理）

它关注的是细微纹理。比如**瓦楞纸板的波浪纹**、**编织袋的网格纹**，LBP能看得清清楚楚。

这次，模型训练速度飞快，只要零点几秒。但准确率呢？最高也只有56%。

因为很多垃圾的纹理很相似啊！比如光滑的**塑料瓶**和**玻璃瓶**，在纹理上就很难区分。

第三副：Color眼镜（看颜色）

这副眼镜最简单，也最有效！它直接统计图片的颜色分布。

绿色的菜叶、蓝色的矿泉水瓶、棕色的纸箱——颜色特征太明显了！

结果你看：KNN的准确率直接从40%飙到**70%**，逻辑回归也到了69%。

这说明啊，在垃圾分类里，**颜色往往是最直接、最有力的证据**。

【第三幕：组合出击，真相浮现】

既然平面视觉有局限性，那我们试试**内网出口**。

HOG+颜色：效果还行，逻辑回归冲上了70%。但KNN却暴跌到49%。

为什么呢？你想啊，KNN这个算法，是靠计算样本间的距离来分类的。HOG特征维度太高，有8000多维，就像在一个巨大的广场上找人，两点之间看似很近，其实隔了十万八千里——这就是“**维度灾难**”，把KNN搞懵了。

HOG+LBP：效果平平。没有颜色信息，就像破案时只掌握了嫌疑人的身高和指纹，却不知道他穿什么颜色的衣服，很难锁定目标。

LBP+颜色：黄金组合出现了！

KNN准确率达到了73.7%，而且所有模型训练速度都极快。

你看，我们**去掉了干扰项HOG**，保留了最关键的**颜色**和辅助的**纹理**。这就好比侦探破案，抓住了“蓝色工装”（**颜色**）和“手部老茧”（**纹理**）这两个核心特征，立刻就能缩小范围，效率大增。

【第四幕：数据“投喂”与参数“微调”】

有了最好的特征组合，我们进入第五阶段：**给模型“多吃点”、“吃好点”**。我们通过翻转、旋转图片，把数据量扩充到8000多张，并调整了模型参数。

结果，SVM的表现非常亮眼，准确率冲到了**78.1%**，逼近80%大关。

这说明，对于SVM这种复杂的模型，**更多的数据和更精细的调节，能让它画出更完美的分类边界**。

但其他的简单模型，比如KNN和逻辑回归，提升就非常有限了。

这就像学生做题，KNN是那种死记硬背的学生，题海战术（数据增强）对它作用不大；而SVM是尖子生，给的题目越多样，它总结的解题方法（分类超平面）就越精妙。

【第五幕：召唤“王牌模型”】

单模型似乎触及了天花板，那我们请出更强大的“王牌模型”——集成学习和神经网络。

随机森林：它就像组建了一个**专家评审团**。100棵树，每棵都从不同角度（不同特征子集）看问题，最后投票决定。结果，准确率78.8%，**训练只用了0.42秒**，又快又准。

XGBoost：它更厉害，像是一个**不断纠错的学习小组**。后一个模型专门学习前一个模型犯的错。结果，准确率**首次突破80%，达到83.2%**，成为新的王者。

MLP（神经网络）：它仿照人脑，建立了多层网络来理解特征。准确率也达到了79.2%。

你看，当特征工程做到位后，**算法的复杂度，就决定了性能的天花板**。

【第六幕：激进化的冒险与反思】

我们不甘心，想看看天花板到底有多高，于是进行了激进的参数调优。

结果很有意思：

XGBoost冲到了**87%**的惊人准确率，但训练时间也暴涨到**94秒**。随机森林准确率提升一点点，但耗时翻了20倍。

而MLP的准确率反而**下降了**。

这告诉我们一个道理：**模型的优化不是无限制的**。过分追求极致，就像把发动机转速拉到红线，虽然可能更快一点，但油耗剧增（耗时暴漲），甚至可能损伤引擎（过拟合，泛化能力下降）。

87%的准确率，很可能就是当前数据和特征下，传统机器学习的“性能墙”了。

【最终幕：效率的终极魔法】

最后，我们做了两件事来提升效率：

第一，PCA降维：试图给数据“瘦身”。

结果对神经网络MLP效果很好，耗时大降。但对依赖具体特征的XGBoost，准确率损失较大。这说明，**有些信息是不能随便压缩的**，就像你不能把破案的关键证据给模糊掉。

第二，GPU加速：这才是真正的魔法！

我们用上NVIDIA显卡和CUDA加速库。

效果立竿见影：**XGBoost的训练时间从51秒猛降到17秒，而准确率依然保持在86%的高位！**
这为我们未来部署实时分类系统，提供了坚实的技术基础。

【大结局：谁是MVP？】

好，我们回顾整个“破案”过程：

- **准确率MVP：XGBoost**，以87%的准确率夺冠。
- **效率MVP：随机森林**，在精度和速度间取得了最佳平衡。
- **单模型战士：SVM**，在精心调教后，表现始终稳健。

当然，我们还请出了“外援”**CNN (ResNet50)**，它用深度学习方法，达到了**94.3%**的准确率，展示了深度学习的强大潜力。但这需要更长的训练时间和更强的算力。

所以，最终的结论是：

没有最好的算法，只有最合适的场景。

如果你追求极致的精度且资源充足，CNN是方向。

如果你需要在**精度、速度和可解释性**之间取得平衡，那么**“LBP+颜色特征”配合XGBoost或随机森林**的机器学习方案，是一个非常优秀、可靠的选择。

我们的探索暂时告一段落，但技术前进的脚步不会停止。未来，模型融合、轻量化部署将是新的挑战。

我的汇报到此结束，感谢各位老师的聆听，欢迎提问！